

A/B тест новой формы оплаты ЖКХ с упрощённым заполнением реквизитов.

• Разведочный анализ данных (EDA)

Книга содержит два листа.

На первом листе «Пользователи» справочник пользователей. 5 колонок.

- user_id — уникальный идентификатор пользователя в пределах 1001 — 2500. Но есть четыре нестандартных значения (последние четыре строки)
- group — группа для теста. Содержит один пропуск в последней строке
- age — возраст от 20 до 60. Есть два нестандартных значения «150» и «-5» в последних строках
- city — город. Один пропуск в последней строке
- device_type — тип устройства. Пропусков и выбросов нет.

На втором листе «Платежи» семь колонок

- payment_id — уникальный идентификатор платежной операции от 5001 до 7658. И три значения нестандартные в последних строках
- user_id — идентификатор пользователя, совершившего операцию. Один пропуск в последних строках
- group — группа для теста. Нет пропусков
- step1_opened, step2_entered, step3_confirmed, step4_success — столбцы с датами и временем прохождения этапа операции


• Работа с выбросами и некорректными записями

Последние четыре строки на листе «Пользователи» с пропусками и нестандартными значениями, принял решение их удалить.

На листе «Платежи» нестандартные значения в последних трех строках. Их тоже исключил.

Дополнительно в столбцах с датами и временем проверил, что значения в столбцах справа всегда больше значения в столбце слева. Все корректно.

Для уверенности проверим сбалансированность выборок по основным столбцам.





• Визуализация результатов

Воронка конверсии

Шаг	Группа А	Группа В
Открыли форму (шаг 1)	100% (1309)	100% (1352)
Ввели реквизиты (шаг 2)	81% (- 248)	88% (- 157)
Подтвердили платёж (шаг 3)	58% (- 303)	71% (- 234)
Успешная оплата (шаг 4)	50% (- 107)	64% (- 90)

Потеря на втором и третьем шагах в группе В сильно меньше как количественно, так и в процентном выражении.



- Статистическая проверка гипотез (с обоснованием выбранного метода)

Нулевая гипотеза H_0 : конверсия в группе В $\leq$ конверсии в группе А.

Альтернативная гипотеза H_1 : конверсия в группе В $>$ конверсии в группе А.

Z-тест для пропорций

Тип данных — бинарный. Есть только два варианта: успешная оплата или нет. Выборка большая (750 пользователей) и независимая (в разные группы входят разные пользователи). Распределение стремится к нормальному.

$$p = (\text{Успешные платежи А и В}) / (\text{Всего платежи А и В}) = (651 + 871) / (1309 + 1352) = 0.57$$

$$\text{Стандартная ошибка } Se = \sqrt{0.57 \cdot (1 - 0.57) \cdot (1/1309 + 1/1352)} = 0.0192$$

$$Z = (p_B - p_A) / Se = (0.64 - 0.50) / 0.0192 = 7.29$$

$$d = Z \cdot Se = 7.29 \cdot 0.0192 = 0.14$$

$$p\text{-value} = 1 - F(7.29) = 1 - 0.99 (< 0.05)$$

Доверительный интервал $(+/-) 1.96 \cdot Se$

$$[0.14 - 1.96 \cdot 0.0192; 0.14 + 1.96 \cdot 0.0192]$$

$$[10.24\%; 17.76\%]$$

- Формулировка рекомендации на основе данных

p-value очень маленькое, доверительный интервал узкий и положительный. Отвергаем нулевую гипотезу на уровне значимости 5%. Новая форма статистически значимо увеличивает долю успешных оплат.